پیاده سازی روش های پردازش زبان
بر روی داده های توییتر

مقدمه

در اینجا، سه مسئله علوم داده با استفاده از داده های توییتر مطرح شده است که هدف از آن ها پیاده سازی پیش پردازش متون و داده های عددی، مدل سازی داده ها با استفاده از روش های یادگیری ماشین و بکارگیری روش های مناسب برای بهبود عملکرد آن است.

مسائل

1- دسته بندی متون

1-1- داده ها

در جدول زیر، تعداد و نوع داده ها را مشاهده میکنیم. داده ها شامل متن توییت، URL های استفاده شده در آنها، تعداد یک سری ویژگی های مربوط به توییت مانند لایک ها و ریپلای ها، و همچنین متون نقل قول شده است. متغیر هدف ستون با نام relevant است که مرتبط یا نامرتبط بودن توییت را مشخص میکند.

```
RangeIndex: 7591 entries, 0 to 7590
Data columns (total 13 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   in_reply_to_user_id  3542 non-null   float64
 1   is_quote             7591 non-null   bool
 2   is_retweet           7591 non-null   bool
 3   like_count           7591 non-null   int64
 4   quote_count          7591 non-null   int64
 5   quoted_text          575 non-null    object
 6   reply_count          7591 non-null   int64
 7   retweet_count        7591 non-null   int64
 8   retweet_text         0 non-null      float64
 9   text                 7591 non-null   object
 10  urls_expanded_url    3747 non-null   object
 11  urls_url             3747 non-null   object
 12  relevant             7591 non-null   object
dtypes: bool(2), float64(2), int64(4), object(5)
```

1-2- هدف

دسته بندی توییت ها به دو دسته مرتبط و نامرتبط با استفاده از روش های یادگیری ماشین.

1-3- روش

ابتدا داده ها را نمایش میدهیم و مشاهده میکنیم ستون retweet_text هیچ داده ای در خود نگه نمیدارد، پس این ستون را حذف میکنیم. ستون is_reply_to_user_id شامل اطلاعات کاربری است که این توییت یک ریپلای به آن است. از این ویژگی، یک ویژگی جدید با نوع داده boolean با عنوان is_reply استخراج میکنیم. ستون is_quote اگر true باشد به

معنای این است که یک متن نقل قول شده در توییت استفاده شده و این متن در ستون quoted_text آمده، از طرفی این متن نقل قول شده در متن توییت اصلی نیز آمده، پس ستون quoted_text را حذف میکنیم زیرا که اطلاعات آن در دو ستون is_quote و text آمده است. دو ستون urls_url و urls_exapnded_url آدرس هایی که در متن توییت آمده است را بصورت short و expanded، به ترتیب، نگه میدارند. ما در اینجا آدرس ها را پردازش نمیکنیم و از این اطلاعات ویژگی جدید به نام url_count استخراج میکنیم که تعداد آدرس های بکار برده شده در هر توییت را نگه میدارد.
در جدول زیر، اطلاعات آماری مربوط به داده های عددی آمده است. با مشاهده سه چارک اول در داده های مربوط به count، متوجه میشویم در خود داده های outlier دارند زیرا که چارک سوم مقدار صفر یا یک دارد در حالی که مقدار ماکزیمم این متغیرها به چند هزار میرسد.

	in_reply_to_user_id	like_count	quote_count	reply_count	retweet_count
count	3.542000e+03	7591.000000	7591.000000	7591.000000	7591.000000
mean	3.194062e+17	11.169938	0.318667	1.375972	2.106705
std	5.055444e+17	198.442037	6.581126	29.109233	29.621685
min	1.200000e+01	0.000000	0.000000	0.000000	0.000000
25%	2.581237e+07	0.000000	0.000000	0.000000	0.000000
50%	4.328953e+08	0.000000	0.000000	0.000000	0.000000
75%	8.300799e+17	1.000000	0.000000	1.000000	0.000000
max	1.357398e+18	15352.000000	486.000000	2261.000000	2275.000000

سپس به سراغ متغیر هدف میرویم. مقادیر دو کلاس را مشاهده میکنیم و متوجه میشویم که داده ها بالانس نیستند و کلاس مثبت تقریبا 6 برابر کلاس منفی است. به این دلیل از متریک های precision، recall و f1-score برای ارزیابی عملکرد مدل استفاده میکنیم تا مشاهده کنیم که آیا مدل میتواند کلاس کوچکتر را تشخیص دهد.

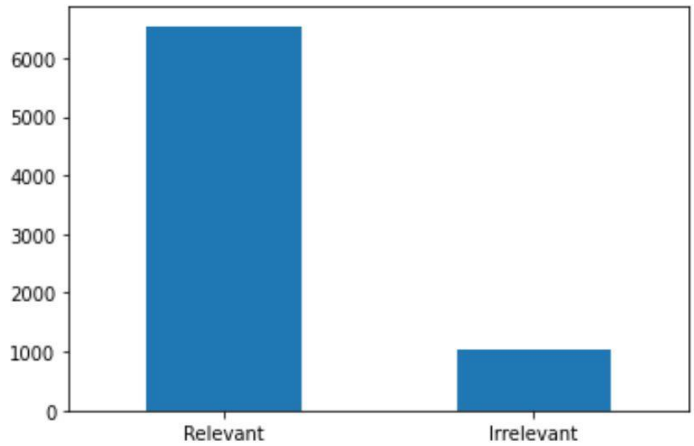

حال از داده های عددی boxplot رسم میکنیم تا با استفاده از آن بتوانیم محدوده ای برای outlier ها انتخاب کنیم.

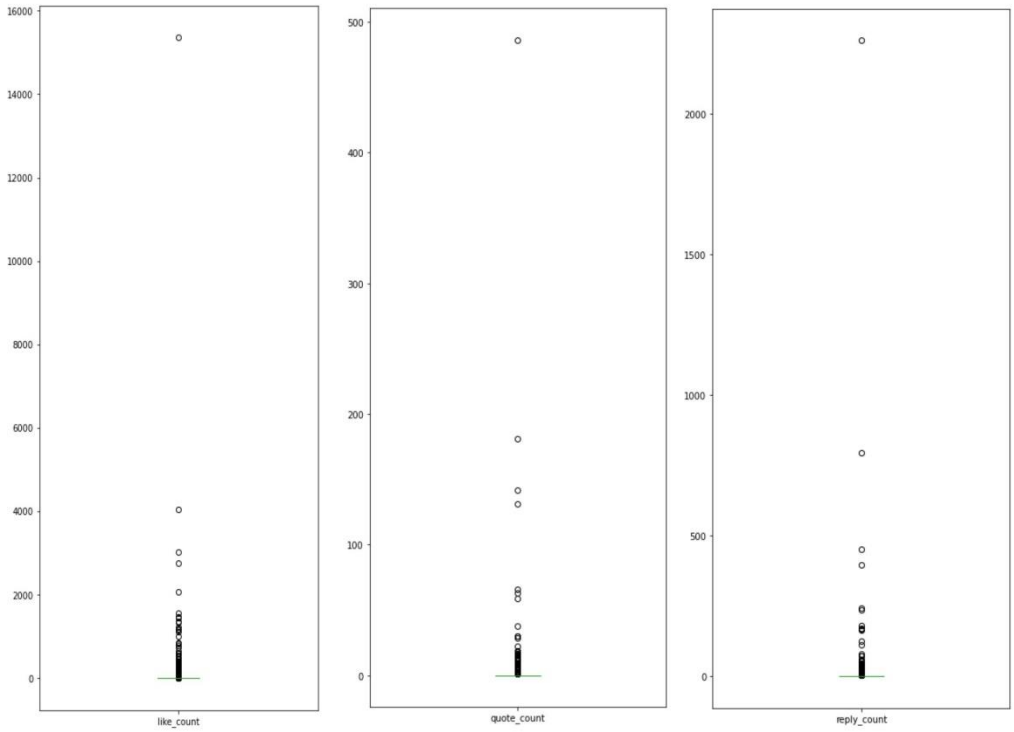

در نمودار های بالا، تمرکز داده ها و نقاط دورافتاده را مشاهده میکنیم. برای هرکدام محدوده ای تعیین میکنیم و مقادیر خارج از آن محدوده را حذف میکنیم که در نهایت تعداد 9 داده از داده ها حذف میشود. با رسم دوباره boxplot مشاهده میکنیم پراکندگی نقاط کمتر است.

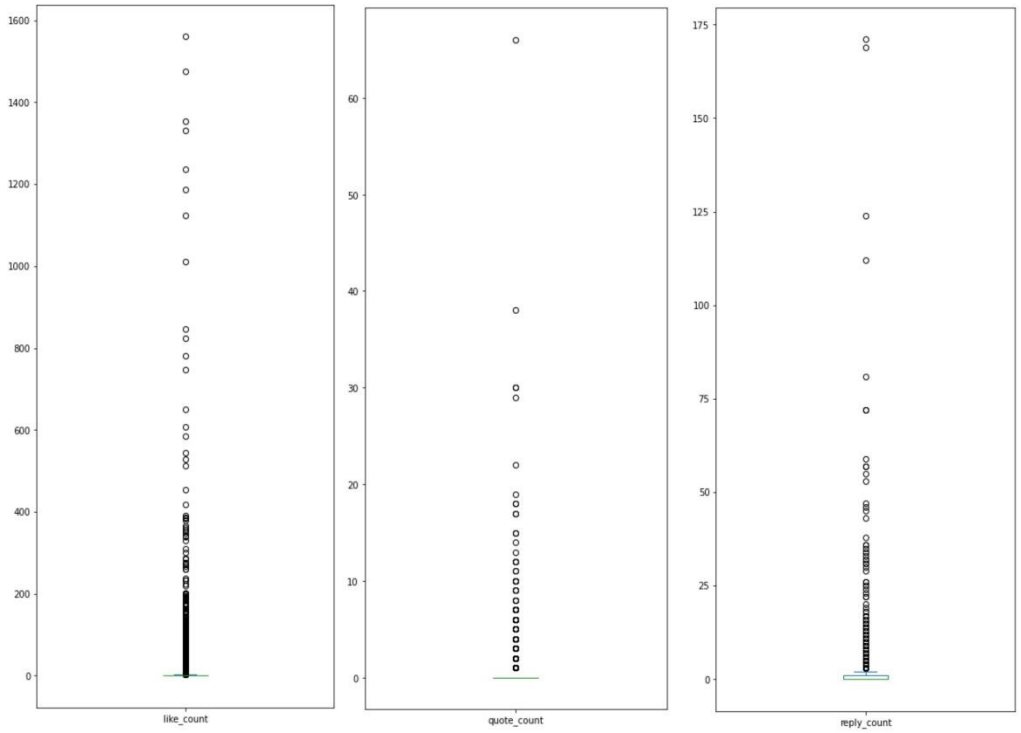

در مرحله بعد، برای مشاهده پراکندگی داده های عددی نسبت به یکدیگر و به متغیر هدف، از این داده ها pairplot رسم میکنیم.

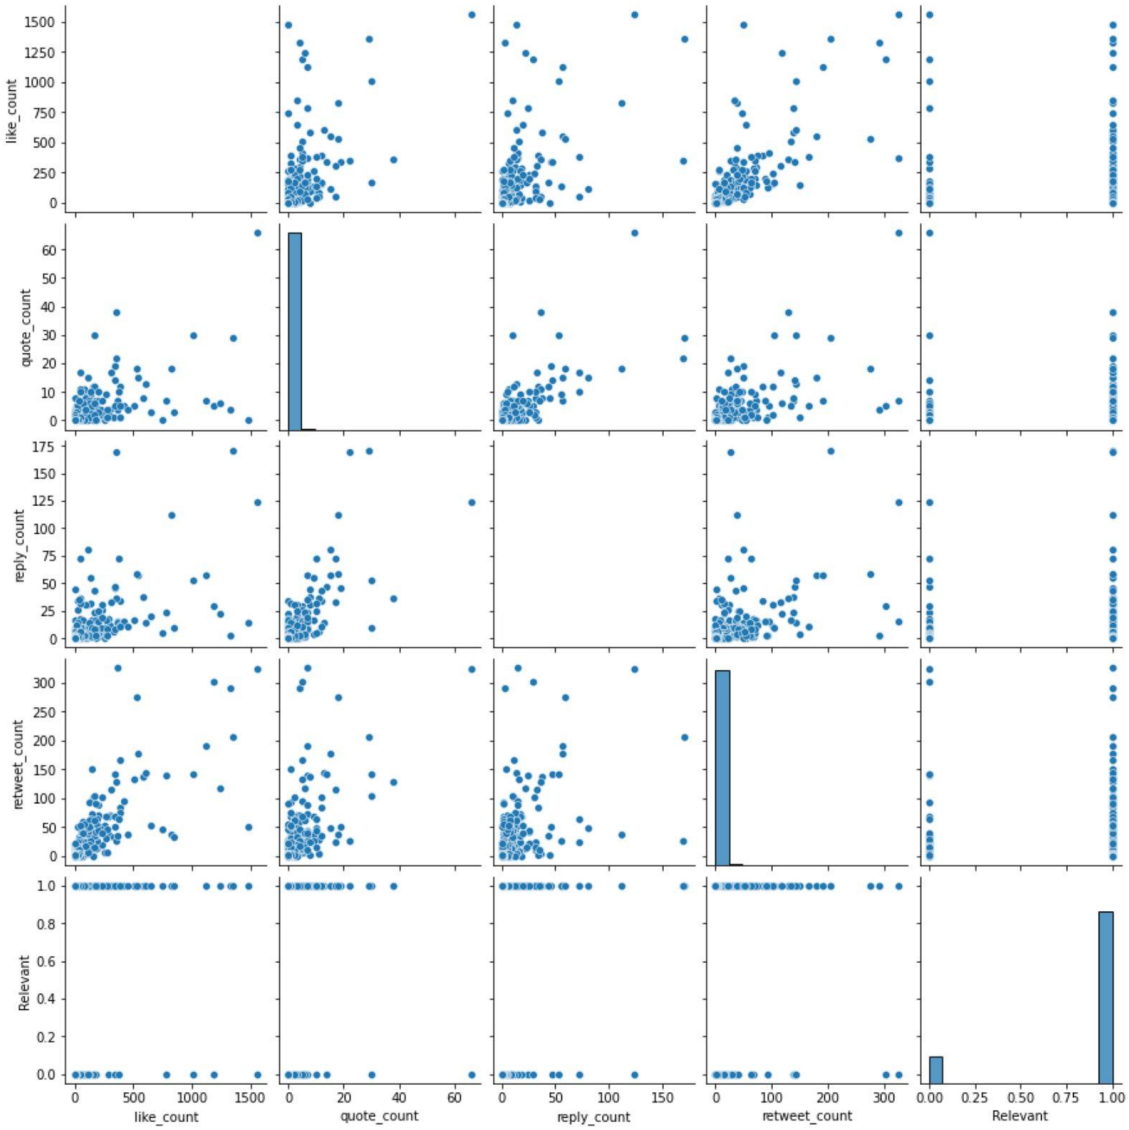

مشاهده میکنیم هیچکدام از جفت ویژگی ای با یکدیگر ارتباط خطی ندارند. از این نمودار همچنین میتوانیم اینکه اگر پراکندگی یک ویژگی نسبت به ویژگی های دیگر ثابت باشد را استخراج کنیم که در اینصورت این ویژگی را حذف میکنیم زیرا اطلاعات اضافه ای به ما نمیدهد. در اینجا چنین توزیعی مشاهده نمیکنیم.

به علت اینکه توزیع این ویژگی ها نرمال نیست، از آنها لگاریتم طبیعی میگیریم تا توزیع آنها به توزیع نرمال نزدیک شود ولی مشاهده کردیم تغییر محسوسی ایجاد نشد.

حال به سراغ پیش پردازش متون میرویم و punctuation، URL، اعداد و stopwords را از آنها حذف میکنیم، سپس stemming را بر روی کلمات پیاده میکنیم.

```
StopWords = stopwords.words('english')
def clean_tweet(tweet):
    if type(tweet) == float:
        return ""
    # lowercase all the letters
    temp = tweet.lower()
    # remove mentions and hashtags
    temp = re.sub(r"@(\w)+", "", temp)
    temp = re.sub(r"#(\w)+", "", temp)
    # remove links
    temp = re.sub(r"http\S+", "", temp)
    temp = re.sub(r"www.\S+", "", temp)
    # remove non-alphanumeric characters
    temp = re.sub(r"(\d|\W)+", " ", temp)
    # tokenization
    temp = word_tokenize(temp)
    # remove stopwords
    temp = [word for word in temp if word not in StopWords]
    # stem words
    ps = PorterStemmer()
    temp = [ps.stem(word) for word in temp]
    # join words back together
    temp = " ".join(temp)
    return temp
```

در اینجا، دو مرحله از پیش پردازش شامل normalization برای داده های عددی و bag of words برای متون باقی مانده که ابتدا نیاز است داده های train و test را جدا کنیم تا data leakage اتفاق نیفتد.

ابتدا داده ها را جدا میکنیم و برای این کار 33 درصد داده ها را به test اختصاص میدهیم.

سپس از MinMaxScaler برای normalization و از CountVectorizer برای bag of words استفاده میکنیم. این الگوریتم ها را ابتدا روی داده های train مدل میکنیم و روی هر دو داده پیاده میکنیم.

در قدم بعدی، داده ها را مدل میکنیم. ابتدا از الگوریتم Random Forest استفاده کردیم و بعد از مدلسازی، دیتای تست را به آن دادیم تا پیش بینی کند. مشاهده میکنیم دقت خیلی کمی بر روی کلاس منفی دارد.

	precision	recall	f1-score	support
0	0.31	0.04	0.07	346
1	0.86	0.99	0.92	2157
accuracy			0.86	2503
macro avg	0.59	0.51	0.49	2503
weighted avg	0.79	0.86	0.80	2503

سپس از الگوریتم XGBoost استفاده میکنیم و مشاهده میکنیم دقت آن بر روی کلاس منفی از Random Forest کمتر است.

	precision	recall	f1-score	support
0	0.14	0.01	0.03	346
1	0.86	0.99	0.92	2157
accuracy			0.85	2503
macro avg	0.50	0.50	0.47	2503
weighted avg	0.76	0.85	0.80	2503

برای بهبود عملکرد مدل روی کلاس کوچکتر از چندین روش resampling استفاده میکنیم. روش های Random Undersampling، Random Oversampling، SMOTE، SVMSMOTE و SMOTETomek را پیاده میکنیم و نتایج روی مدل logistic regression مشاهده میکنیم. در بین این روش ها SMOTE بیشتر به بهبود عملکرد مدل کمک میکند و البته روش SMOTETomek عملکرد مشابه SMOTE نشان میدهد.

logistic regression model with SMOTE-oversampled training data

	precision	recall	f1-score	support
0	0.23	0.32	0.27	346
1	0.88	0.82	0.85	2157
accuracy			0.75	2503
macro avg	0.56	0.57	0.56	2503
weighted avg	0.79	0.75	0.77	2503

با استفاده از این روش، عملکرد مدل بر روی کلاس کوچکتر بهتر میشود ولی همچنان عملکرد مطلوبی ندارد. برای بهتر شدن عملکرد آن، میتوانیم به سراغ ویژگی ها برویم و ببینیم آیا کاهش آن ها میتواند به بهتر شدن نتایج کمک کند، یا به مرحله پیش پردازش بازگردیم و با انجام پردازش بیشتر بر روی داده ها عملکرد مدل را بهبود بخشیم. این امر در فاز های بعدی پروژه انجام خواهد شد.